한국어 위험 발화 탐지를 위한 진성/비진성 판별 모델과 우울/불안 판별 모델

HyunJoon Lee

SimSimi Inc.

초록 — 본 논문은 한국어 위험 발화 탐지 테스트 도구 riskcheck와 함께 배포되는 기본 판별 모델 두 종을 기술한다. 첫째 모델은 자살·자해 등 위해 표현을 담은 발화가 실제 위해 의도를 포함하는지를 판별하는 진성/비진성 판별 모델로, KcELECTRA-base를 파인튜닝하고 백본 승급과 최소대립쌍 학습 자료를 도입해 블라인드 평가셋에서 F1 0.8268 (Recall 0.8409, Precision 0.8132)을 달성했다. 둘째 모델은 발화에서 우울·불안 신호를 탐지하는 감정 판별 모델로, KoELECTRA-small 공유 인코더에 게이트와 감정별 이진 헤드를 결합한 구조이며 지식 증류로 구축한 라벨로 학습했다. 기준 평가 팩에서 불안 헤드는 AUC 0.974, 재현율 0.94를 기록했다. 두 모델의 구조, 학습 데이터, 학습 방법, 평가 결과 및 한계를 함께 제시한다.

키워드: 위험 발화 탐지, 진성/비진성 판별, 감정 분류, 지식 증류, 한국어 언어모델

1. 서론

대화형 서비스에서 사용자의 발화를 분석해 위험상황을 포착하려면 세 가지 판별이 필요하다. 첫째, 자살·자해와 같은 위해 표현 자체의 탐지이다. 둘째, 탐지된 표현이 실제 위해 의도를 담고 있는지의 판별이다. 위해 표현은 "죽고 싶다"는 직접 진술 외에도 타인의 소식을 전하는 발화, 노래 가사나 대사 인용, "배고파 죽겠다"와 같은 과장, 이미 해소된 과거사의 회고 등 의도가 없는 형태로 빈번하게 나타나므로, 표현의 존재만으로 위험을 확정할 수 없다. 셋째, 우울·불안과 같은 감정 신호의 탐지이다. 우울·불안은 위해 표현 없이 감정 상태의 서술로 나타나며, 위해 경로와는 독립적으로 위험 신호가 된다.

첫째 판별은 단어 사전 기반 탐지로 폭넓게 수행할 수 있다. 사전은 어휘를 기계적으로 포착하는 장치라 포착 범위가 곧 시스템 탐지 범위의 상한이 되지만, 진성과 비진성을 가리지는 못한다. 따라서 둘째 판별을 담당하는 학습 기반 판독 모델과, 셋째 판별을 담당하는 감정 판별 모델이 필요하다.

본 논문은 한국어 위험 발화 탐지 테스트 도구 riskcheck [1]의 기본 모델로 배포되는 판별 모델 두 종을 기술한다. 2절의 진성/비진성 판별 모델은 위해 축을 담당한다. 사전이 포착한 발화에 대해서는 진성 여부를 확인해 비진성 발화를 걸러내고, 사전이 포착하지 못한 발화에 대해서도 위해 확률을 산출해 단독으로 판정할 수 있다. 3절의 우울/불안 판별 모델은 감정 축을 담당해 발화의 우울·불안 확률을 산출한다. 4절에서는 두 모델이 riskcheck에서 결합되는 방식을, 5절에서는 결론을, 6절에서는 라이선스와 데이터 출처를 제시한다.

2. 위해 진성/비진성 판별 모델

2.1 모델 구조

본 모델은 한국어 뉴스 댓글로 사전학습된 ELECTRA인 KcELECTRA-base [2]를 파인튜닝한 이진 분류 모델이다. 댓글 코퍼스로 사전학습된 백본을 선택한 것은 위해 발화가 구어체 단문으로 나타나는 경우가 많기 때문이다. 입력은 발화 텍스트 1건이며, 맥락이 필요한 경우는 연속 발화를 공백으로 연결한 단일 입력으로 구성한다. 최대 입력 길이는 96 토큰으로 절단한다. 출력은 비진성(인덱스 0)과 진성(인덱스 1)에 대한 softmax 확률이다. 모델 사양을 표 1에 정리했다.

표 1. 위해 진성/비진성 판별 모델 사양

항목	내용
백본	beomi/KcELECTRA-base-v2022
구조	ElectraForSequenceClassification (은닉 차원 768, 12층, 어텐션 헤드 12, 어휘 54,343)
파라미터	127.8M
입력	발화 텍스트 (최대 96 토큰)
출력	2클래스 확률 (비진성 / 진성)

2.2 판별 기준과 데이터셋

판별 기준은 발화 시점의 위해 의도 유무이다. 진성은 화자 본인의 위해 사고(G1), 의도·계획(G2), 행위(G3), 과거 고백(G4)으로 구성된다. 과거 고백은 이미 종료된 행위의 고백이지만, 위해 경험 자체가 위험 신호이므로 진성에 포함한다. 비진성은 타인에 대한 언급, 인용·전달, 부정, 과장·관용 표현, 해소된 과거 상태, 방법·정보 질문 등 위해 표현을 포함하되 화자 본인의 현재 의도가 없는 경우이다. 어느 쪽으로도 확정할 수 없는 경우는 판정 보류로 분리해 학습과 채점에서 다르게 취급한다.

학습 데이터는 외부 공개 데이터를 사용하지 않고 자체 구축했다. 위해 표현 시나리오를 기반으로 생성한 문장 2,120건과, 규칙 기반 탐지기의 테스트 케이스 271건에 위 판별 기준을 적용해 라벨링한 문장으로 구성된다. 전체 구성은 표 2와 같다.

표 2. 위해 판별 데이터셋 구성

구분	건수
진성 (genuine)	1,021
비진성 (non_genuine)	1,220

구분	건수
판정 보류 (unsure)	150
합계	2,391
단문 / 맥락 (연속 2~4발화)	1,991 / 400

데이터는 학습/개발/검증으로 1,913/239/239건을 라벨 층화 분리했다. 실제 학습에는 판정 보류를 제외한 학습분 1,793건에 보강 자료 290건을 더한 2,083건(진성 900건)을 사용했다. 보강 자료는 감정 호소형 비진성 84건, 오답 분석 기반 난케이스 130건, 최소대립쌍 76건으로 구성된다.

최소대립쌍은 같은 위해 신호 문장에 결말만 바꾼 쌍으로 구성한 학습 자료이다. 예를 들어 같은 과거 위해 신호를 포함하는 문장이라도 결말이 현재 상태의 진술이면 해소(비진성), 상태 호전의 진술이면 과거 고백(진성), 신호의 잔존 진술이면 현재 사고(진성)로 라벨이 갈리도록 만들어, 표면 어휘가 아니라 결말의 상태 서술이 판별 근거가 되도록 학습시킨다.

2.3 학습 방법

모델은 세 단계를 거쳐 개선했다. 기준선 모델(v0)은 KoELECTRA-small [3] 백본으로 구축했다. v1에서는 평가 오답을 분석해 반복적으로 틀리는 유형 — 타인 소식 보고형과 과거 해소형의 비진성, 진심을 강조하는 형태의 진성 — 을 난케이스로 보강했다. v2에서는 백본을 KcELECTRA-base로 승급하고 최소대립쌍 학습 자료를 추가했다. 단계별 결과는 2.4절의 표 4에 함께 제시한다.

학습 설정은 3 epoch, 학습률 2e-5, 배치 크기 32이며, 개발셋 F1이 최대인 체크포인트를 선택했다. 출력 확률에 대한 별도의 사후 보정(온도 조정 등)은 적용하지 않았으며, 모든 지표는 원 확률 기준이다.

2.4 실험 결과

평가는 학습 데이터와 분리된 블라인드 평가셋 300건으로 수행했다. 기준 라벨은 판정 지시문에 따라 최고 성능 모델 2종이 독립 판정하고 불일치는 중재 절차로 확정한 것이다. 평가셋의 구성은 진성 88건, 비진성 176건, 판정 보류 36건이며, 완곡·경계 표현의 비중이 높은 고난도 구성이다. 판정 보류는 지표에서 제외하고 264건을 기준 확률 0.5로 채점했다.

표 3. 위해 판별 모델 평가 결과 (블라인드 평가셋 264건)

지표	값
Recall	0.8409
Precision	0.8132
F1	0.8268
단문 F1 / 맥락 F1	0.8116 / 0.8780

지표	값
진성 하위 회수율 — 사고(G1)	0.861
진성 하위 회수율 — 의도/계획(G2)	0.900
진성 하위 회수율 — 행위(G3)	0.813
진성 하위 회수율 — 과거 고백(G4)	0.750

맥락 입력의 F1(0.8780)이 단문(0.8116)보다 높아, 연속 발화의 상태 서술이 판별에 기여함을 확인했다. 하위 회수율은 의도/계획(G2)이 가장 높고 과거 고백(G4)이 가장 낮다. 고백형은 해소형 비진성과 표면 형태가 유사해 구분이 어려운 유형이다.

표 4. 버전별 골드 평가 F1

버전	변경 사항	F1
v0	KoELECTRA-small 기준선	0.576
v1	오답 분석 기반 난케이스 보강	0.578 (중단된 학습의 최적 체크포인트 기준)
v2	KcELECTRA-base 승급 + 최소대립쌍 추가	0.827

난케이스 보강만으로는 골드 F1이 거의 움직이지 않았고(0.576 → 0.578), 백본 승급과 최소대립쌍을 결합한 단계에서 큰 폭으로 향상됐다(0.827). 두 변경을 동시에 적용했으므로 개별 기여는 분리할 수 없으나, 하위 유형별로는 과거 고백(G4) 회수율이 0.438에서 0.750으로 회복되어 최소대립쌍이 해당 경계에 기여한 것으로 보인다.

내부 검증셋(224건, 판정 보류 제외)에서는 Precision 0.9798, Recall 0.9327, F1 0.9557을 기록했다. 다만 내부 검증셋은 학습 데이터와 같은 생성 분포에서 만들어졌으므로 실제 분포보다 낙관적인 수치로 해석해야 하며, 본 논문은 블라인드 평가셋 지표를 대표 수치로 삼는다.

2.5 한계

첫째, 학습과 평가가 모두 생성 데이터에 기반한다. 실제 사용자 발화 분포에서는 검증되지 않았으므로, 실분포 성능은 별도의 검증이 필요하다. 둘째, 판정 보류 케이스에서 진성 쪽으로 기우는 경향이 있다. 평가셋의 판정 보류 36건 중 69.4%를 진성으로 출력해, 경계 발화에서는 과탐지 방향으로 오차가 치우친다. 셋째, 과거 고백(G4)의 회수율이 가장 낮다. 넷째, 맥락 입력은 발화를 단순 연결하는 방식이라 화자 구분이나 턴 구조를 모델링하지 않는다.

3. 우울/불안 판별 모델

3.1 모델 구조

본 모델은 KoELECTRA-small [3] 백본의 공유 인코더 위에 두 종류의 출력을 결합한 다중 과제 구조이다. 게이트는 우울·불안·기타부정·평온의 4분류 확률(softmax)을 출력하고, 감정별 이진 헤드 11개는 각 감정에 대한 확률(sigmoid)을 출력한다. 전체 출력 15개의 구성은 표 5와 같다. 입력은 한국어 단문 발화이며 최대 64 토큰으로 절단한다. 파라미터는 약 14.1M이다.

표 5. 우울/불안 판별 모델 출력 구성

인덱스	출력	종류
0	우울	게이트 (softmax)
1	불안	게이트 (softmax)
2	기타부정	게이트 (softmax)
3	평온	게이트 (softmax)
4	긴장	헤드 (sigmoid)
5	피로	헤드 (sigmoid)
6	우울	헤드 (sigmoid)
7	불안	헤드 (sigmoid)
8	스트레스	헤드 (sigmoid)
9	분노	헤드 (sigmoid)
10	슬픔	헤드 (sigmoid)
11	외로움	헤드 (sigmoid)
12	무기력	헤드 (sigmoid)
13	수치자책	헤드 (sigmoid)
14	당황혼란	헤드 (sigmoid)

riskcheck에서는 감정 헤드의 우울(인덱스 6)·불안(인덱스 7) 확률만 신호로 사용한다. 게이트 확률은 클래스 간 경쟁값이라 클래스별 기준 확률로 판정하는 용도에 적합하지 않아 사용하지 않으며, 게이트용으로 고안된 마진 판정 규칙 역시 이식하지 않는다.

3.2 데이터셋과 라벨 구축

학습 데이터는 총 35,482건으로, 한국어 코퍼스 발화 31,682건과 생성 문장 3,800건으로 구성되며 학습/개발/검증으로 30,740/1,579/3,163건을 분리했다. 코퍼스 발화의 출처별 구성(학습 라벨 파일에 기록된 출처 태그 기준)은 표 6과 같다. 데이터 원본은 배포하지 않는다.

표 6. 코퍼스 발화 출처별 구성 (31,682건)

출처	건수	비고
감성 대화 말뭉치 (AI 허브)	14,000	우울·인접 감정 발화와 초조·걱정·불안 채굴분
연속적 대화 (AI 허브)	6,437	부정·중립 발화
공감형 대화 (AI 허브)	3,998	부정 세션 발화
웰니스 대화 스크립트 (AI 허브)	3,878	초조함·흥미 감소·피로 등 증상 발화
대화 채굴분	2,940	대화 코퍼스에서 채굴한 발화
KOTE	429	댓글 일부

라벨은 상용 감정 판정 모델의 12종 감정 확률 분포를 교사 라벨로 사용하는 지식 증류로 구축했다. 대규모 발화에 감정 라벨을 일관되게 부여할 방법이 교사 모델의 판정을 이용하는 것이며, 학생 모델의 성능 목표는 교사 수준의 판별력과 순위를 재현하는 것이다. 교사 확률이 0.6 이상이면 양성, 0.2 이하이면 음성으로 채택하고, 중간 구간은 헤드 학습에서 제외(마스킹)해 경계 구간의 노이즈가 학습을 흐리지 않도록 했다. 우울·불안 헤드 전용 데이터는 두지 않고 전체 학습셋을 공통으로 사용한다.

3.3 학습 방법

공유 인코더 위에 게이트(교차엔트로피 손실)와 감정별 이진 헤드 11개(이진 교차엔트로피 손실, 중간 구간 마스킹)를 동시에 학습하는 다중 과제 파인튜닝을 수행했다. 학습 설정은 배치 크기 64, 3 epoch, 학습률 3e-5, warmup 100 step이다. 게이트를 판정에 사용할 경우를 위해, 부정 버킷의 최대 확률이 평온 확률보다 0.3 이상 클 때만 부정으로 판정하는 마진 규칙도 함께 평가했다 (3.4절).

3.4 실험 결과

평가 기준 라벨은 상용 최고 성능 모델 2종의 판정을 평균한 확률 분포이며, 판정 규칙에 따라 블라인드로 판정했다. 평가셋은 세 가지를 사용했다. 기준 평가 팩 750건은 자연 분포의 대화·댓글 단문으로 구성한 주 평가셋이다. 교사 라벨 검증셋 3,163건은 학습에 쓰지 않은 홀드아웃이며 교사 라벨로 채점한다. 보강 평가 팩 190건은 약한 클래스를 중심으로 표집한 평가셋이다.

표 7. 우울/불안 판별 모델 평가 결과

평가셋	결과
기준 평가 팩 750건	게이트 top-1 일치 0.707 (마진 규칙 시 0.755) · 우울 헤드 재현율@0.5 0.75 · 불안 헤드 AUC 0.974, 재현율@0.5 0.94
교사 라벨 검증셋 3,163건	우울 헤드 AUC 0.938, 재현율@0.5 0.84 · 불안 헤드 AUC 0.905, 재현율@0.5 0.71
보강 평가 팩 190건	우울+불안 합산 신호 Precision 0.923, Recall 0.750, F1 0.828

불안 헤드는 기준 평가 팩과 홀드아웃 모두에서 안정적인 판별력을 보였다. 우울 헤드는 홀드아웃 재현율 0.84를 기록했으나, 기준 평가 팩에서는 양성 표본이 8건에 불과해 재현율 0.75의 신뢰구간이 넓다. 게이트의 마진 규칙은 top-1 일치를 0.707에서 0.755로 올렸으나, 이는 게이트를 최종 판정에 사용할 때의 규칙으로 riskcheck의 헤드 신호 판정에는 적용되지 않는다.

3.5 한계

첫째, 증상형 발화의 탐지가 약하다. 감정어 없이 신체 증상만으로 서술된 발화 — 떨림, 두근거림과 같은 불안의 신체 증상이나 무기력, 흥미 감소와 같은 우울의 증상 서술 — 에서 탐지율이 낮으며, 보강 평가 팩에서 게이트 기준 불안 재현율이 0.000 (양성 20건)을 기록했다. 웰니스 스크립트 기반의 증상 문장은 구어체 증상 서술로의 전이가 부분적이기 때문이다. 둘째, 우울·불안 외 9개 헤드의 재현율@0.5는 기준 평가 팩에서 0.00~0.25 수준으로 단독 신호로 쓰기에 부족하며, 제공 신호를 우울·불안으로 한정한 근거이다. 셋째, 우울 지표의 표본 한계는 3.4절에서 밝힌 바와 같다. 넷째, 짧은 긍정·일상 문장에서 점수가 높게 나오는 과민 반응과, 문장 끝 문장부호 유무에 점수가 민감하게 반응하는 사례가 확인됐다.

4. riskcheck에서의 결합 사용

두 모델은 riskcheck의 기본 모델로 함께 배포되며, 사전 탐지와 결합해 발화 단위 최종 판정을 만든다. 위해 판별 모델은 사전이 포착한 발화에 대해 진성 확률이 0.5 이상일 때 진성으로 확인하고, 진성이 아니라고 판독되면 해당 발화는 사전 포착만으로는 위험이 되지 않는다. 사전이 포착하지 못한 발화에서도 진성 확률이 0.4 이상이면 위해로 판정한다. 우울/불안 판별 모델은 위해 축에서 위험이 확정되지 않은 발화에 대해 우울 또는 불안 헤드 확률이 0.5 이상이면 위험 신호로 판정한다. 최종 판정은 발화마다 하나의 판정으로 확정되며, 단계별 결과는 분리 보관되어 모델 교체 시 해당 단계만 재평가할 수 있다. 두 모델은 각자 다른 모델로 교체할 수 있으며 교체 방법은 riskcheck 문서에 기술되어 있다.

5. 결론

본 논문은 위험 발화 탐지의 두 판별 축을 담당하는 모델 두 종을 기술했다. 위해 진성/비진성 판별 모델은 최소대립쌍과 백본 승급을 통해 블라인드 평가에서 F1 0.8268을 달성했고, 우울/불안 판별 모델은 지식 증류로 구축한 라벨의 다중 과제 학습으로 불안 신호에서 안정적인 판별력을 확보했다. 두 모델의 공통된 한계는 실분포 검증의 부재와 경계·증상형 발화의 탐지율이며, 이는 후속 연구에서 실제 발화 분포의 검증셋 구축과 증상형 재료의 확충으로 다룰 과제이다.

6. 라이선스와 데이터 출처

두 모델의 가중치는 Apache License 2.0으로 배포한다. 백본에서 유래한 부분은 각 백본의 원 라이선스를 따르며, KcELECTRA는 MIT License이다 (Hugging Face 모델 카드 본문에 MIT 표기가 명시되어 있다). KoELECTRA는 Apache License 2.0이다 (공식 GitHub 저장소 기준이며, Hugging Face 허브 페이지에는 라이선스 메타데이터가 등록되어 있지 않다). 우울/불안 판별 모델의 학습에는 AI 허브(https://aihub.or.kr)에서 제공하는 데이터셋을 활용했으며, 연구 결과 공개 시 데이터셋 활용 사실을 밝힌다는 제공 조건에 따라 이를 명시한다.

참고문헌

[1] SimSimi Inc. riskcheck: 한국어 위험 발화 탐지 테스트 도구. https://github.com/simsimi/safety-ruleset-library

[2] Lee, J. (2021). KcELECTRA: Korean comments ELECTRA. https://github.com/Beomi/KcELECTRA

[3] Park, J. (2020). KoELECTRA: Pretrained ELECTRA Model for Korean. https://github.com/monologg/KoELECTRA

[4] Jeon, D. (2022). KOTE: Korean Online Comments Emotions Dataset. https://github.com/searle-j/kote